

生物医学领域词表示项目展示

Word Representation in the Biomedical Domain

Group 3

Imperial College London Data Science and AI Winter School

2025 NLP Project

- ① 任务背景：CORD-19 与生物学 NLP
- ② 数据处理：从论文标题、摘要和全文中抽取语料
- ③ 分词方案：Regex、NLTK、BERT BPE、自定义 BPE
- ④ 表示学习：N-gram、SGNS、Word2Vec、MLM-LoRA
- ⑤ 探索分析：t-SNE、实体聚类、相似词与共现关系
- ⑥ 工程重构：从 notebook 到可复现代码包

核心问题

生物医学学术语具有领域性、组合性和快速演化特征，例如 SARS-CoV-2、ACE2、COVID-19。

- 通用词向量难以充分覆盖专业实体。
- 子词分词有助于处理稀有词和新术语。
- 上下文表示可以捕捉一词多义和语境差异。

项目目标

构建从语料解析、分词、词表示训练到可视化分析的完整生物医学 NLP pipeline。

- 主要参考数据：CORD-19 biomedical literature corpus。
- 项目实施支持三类输入：
 - CORD-19 metadata.csv: title + abstract。
 - CORD-19 parsed JSON: title + abstract + body text。
 - Plain text: one document or sentence per line。
- 仓库中保留了已有 tokenized 数据，便于快速 smoke test。

工程入口

```
python -m biomed_repr.cli prepare-corpus
```

分词方案 / Tokenization Tracks

Track	方法	作用
2.1	Regex tokenizer	快速、稳定、保留连字符术语
2.2	NLTK tokenizer	通用英文分词基线
2.3	BERT tokenizer	预训练 WordPiece 子词
2.4	SimpleBPE / HF BPE	面向领域语料训练子词词表

例子

SARS-CoV-2 binds ACE2 receptors in COVID-19

统计与浅层模型

- N-gram language model
- Co-occurrence + SPPMI + SVD
- Skip-gram Negative Sampling
- Gensim Word2Vec

上下文表示

- BERT Masked Language Modeling
- LoRA adapter fine-tuning
- Lower trainable-parameter cost


轻量本地训练

```
python -m biomed_repr.cli train --model-type cooccurrence ...  
python -m biomed_repr.cli train --model-type ngram ...  
python -m biomed_repr.cli train --model-type sgns ...
```


可选重依赖路径

```
python -m biomed_repr.cli train-word2vec ...  
python -m biomed_repr.cli train-mlm-lora ...
```

整体词向量 t-SNE / Global t-SNE



生物医学实体 t-SNE / Biomedical Entity t-SNE



Similarity Search

给定目标词，例如 coronavirus，计算余弦相似度并导出 nearest neighbors。

Co-occurrence

从窗口共现中观察术语之间的局部关系，辅助发现疾病、症状、治疗和蛋白的关联。

输出

CSV / XLSX 表格，普通 t-SNE 图，实体分组 t-SNE 图。

从 Notebook 到 Package / Refactoring

模块	文件	职责
Corpus	corpus.py	CSV/JSON/text 语料读取
Tokenization	tokenization.py, bpe.py	多种分词方案
Models	representations.py, ngram.py	统计词表示
Models	word2vec.py, mlm.py	神经词表示
Explore	explore.py	相似词、实体、t-SNE、导出
CLI	cli.py	可复现命令入口

- Unit tests cover tokenization, co-occurrence vectors, SimpleBPE, N-gram, and SGNS.
- CLI smoke tests run on existing tokenized samples.
- Heavy dependencies are optional and fail with clear installation messages.
- Original PDFs, notebook, generated figures, and reports are preserved in the repository.

测试命令

```
$env:PYTHONPATH="src"; python -m pytest
```

- 项目实现了生物医学文本的端到端词表示 pipeline。
- 多种分词与建模方法提供了从可解释统计模型到上下文模型的完整路线。
- t-SNE、相似词和实体分组分析展示了词向量的语义结构。
- 重构后的代码包提升了复现性、可维护性和后续扩展空间。

Questions?