

生物医学领域词表示项目展示

Word Representation in the Biomedical Domain

Group 3

Imperial College London Data Science and AI Winter School

2025 NLP Project

开场介绍：本次展示围绕一个问题展开，即如何从大规模生物医学文献中学习可解释、可复现的词表示，并用这些表示支持相似词查询、实体聚类 and 知识发现。

- ① 任务背景：CORD-19 与生物学 NLP
- ② 数据处理：从论文标题、摘要和全文中抽取语料
- ③ 分词方案：Regex、NLTK、BERT BPE、自定义 BPE
- ④ 表示学习：N-gram、SGNS、Word2Vec、MLM-LoRA
- ⑤ 探索分析：t-SNE、实体聚类、相似词与共现关系
- ⑥ 工程重构：从 notebook 到可复现代码包

└ 展示路线 / Talk Roadmap

- 任务背景: CORD-19 与生物医学 NLP
- 数据处理: 从论文标题、摘要和全文中抽取语料
- 分词方案: Regexp, NLTK, BERT BPE, 自定义 BPE
- 表示学习: N-gram, SGNS, Word2Vec, MLM-LoRA
- 探索分析: t-SNE, 实体聚类, 相似词与共现关系
- 工程重构: 从 notebook 到可复现代码包

这一页告诉听众展示结构。强调本项目不只是训练模型，也包括工程化复现：代码被整理为模块、CLI 和测试。

核心问题

生物医学学术语具有领域性、组合性和快速演化特征，例如 SARS-CoV-2、ACE2、COVID-19。

- 通用词向量难以充分覆盖专业实体。
- 子词分词有助于处理稀有词和新术语。
- 上下文表示可以捕捉一词多义和语境差异。

项目目标

构建从语料解析、分词、词表示训练到可视化分析的完整生物医学 NLP pipeline。

生物医学领域词表示项目展示

└ 背景与数据

└ 研究动机 / Motivation

可以用疫情期间新术语迅速出现作为例子。指出为什么 biomedical domain 需要自己的 representation, 而不仅是通用 NLP 模型。

核心问题

生物医学术语具有领域性、组合性和快速演化特征。
例如 SARS-CoV-2, ACE2, COVID-19。

- 通用词向量难以充分覆盖专业实体。
- 子词分词有助于处理稀有词和新术语。
- 上下文表示可以捕捉一词多义和细微差异。

项目目标

构建从语料解析、分词、词表示训练到可
程化分析的完整生物医学 NLP pipeline。

- 主要参考数据：CORD-19 biomedical literature corpus。
- 项目实施支持三类输入：
 - CORD-19 metadata.csv: title + abstract。
 - CORD-19 parsed JSON: title + abstract + body text。
 - Plain text: one document or sentence per line。
- 仓库中保留了已有 tokenized 数据，便于快速 smoke test。

工程入口

```
python -m biomed_repr.cli prepare-corpus
```

生物医学领域词表示项目展示

背景与数据

数据来源 / Data Source

说明原始数据很大，所以展示时使用已有样本和 `limit` 参数做快速复现；完整数据可以用同一入口扩展。

- 主要参考数据: CORD-19 biomedical literature corpus,
- 项目实践支持三类输入:
 - CORD-19 raw data, csv: title + abstract,
 - CORD-19 parsed JSON: title + abstract + body text,
 - Plain text: one document or sentence per line,
- 仓库中保留了已有 tokenized 数据, 便于快速 smoke test,

工程入口

```
python -m biomed_repr.cli prepare-corpus
```

分词方案 / Tokenization Tracks

Track	方法	作用
2.1	Regex tokenizer	快速、稳定、保留连字符术语
2.2	NLTK tokenizer	通用英文分词基线
2.3	BERT tokenizer	预训练 WordPiece 子词
2.4	SimpleBPE / HF BPE	面向领域语料训练子词词表

例子

SARS-CoV-2 binds ACE2 receptors in COVID-19

生物医学领域词表示项目展示

└ 方法

└ 分词方案 / Tokenization Tracks

Track	方法	作用
2.1	Regex tokenizer	快速、稳定、保留连字符术语
2.2	NLTK tokenizer	通用英文分词基线
2.3	BERT tokenizer	预训练 WordPiece 子词
2.4	SimpleBPE / HF BPE	面向领域语料训练子词词典

例子

SARS-CoV-2 binds ACE2 receptors in COVID-19

强调 tokenizer 是后续所有模型的基础。重构后默认 regex 会保留 sars-cov-2、covid-19、ace2 等关键技术语。

统计与浅层模型

- N-gram language model
- Co-occurrence + SPPMI + SVD
- Skip-gram Negative Sampling
- Gensim Word2Vec

上下文表示

- BERT Masked Language Modeling
- LoRA adapter fine-tuning
- Lower trainable-parameter cost

2026-06-05

生物医学领域词表示项目展示

└ 方法

└ 词表示模型 / Representation Models

这一页讲模型谱系：从可解释统计模型到神经词向量，再到上下文模型。说明重构后每个主要 notebook track 都有 CLI 入口。

词表示模型 / Representation Models

统计与浅层模型

- N-gram language model
- Co-occurrence + SPPMI + SVD
- Skip-gram Negative Sampling
- GloVe Word2Vec

上下文表示

- BERT Masked Language Modeling
- LoRA adapter fine-tuning
- Lower trainable-parameter cost

轻量本地训练

```
python -m biomed_repr.cli train --model-type cooccurrence ...  
python -m biomed_repr.cli train --model-type ngram ...  
python -m biomed_repr.cli train --model-type sgns ...
```

可选重依赖路径

```
python -m biomed_repr.cli train-word2vec ...  
python -m biomed_repr.cli train-mlm-lora ...
```

生物学领域词表示项目展示

└─方法

└─建模命令示例 / Reproducible Commands

这里重点不是逐字解释命令，而是展示项目已经从 notebook 变成可重复运行的命令行 pipeline。


轻量本地训练

```
python -m biomed_repr.cli train --model-type cooccurrence ...  
python -m biomed_repr.cli train --model-type agras ...  
python -m biomed_repr.cli train --model-type agas ...
```

可选重复依赖路径

```
python -m biomed_repr.cli train-word2vec ...  
python -m biomed_repr.cli train-wda-lora ...
```

整体词向量 t-SNE / Global t-SNE




2026-06-05

生物医学领域词表示项目展示

└ 结果展示


└ 整体词向量 t-SNE / Global t-SNE

整体词向量 t-SNE / Global t-SNE



解释 t-SNE 的作用：把高维词向量投影到二维，用于直观看相近词是否聚集。提醒听众 t-SNE 是探索工具，不是严格定量证明。


生物医学实体 t-SNE / Biomedical Entity t-SNE



生物医学领域词表示项目展示

└ 结果展示

└ 生物学实体 t-SNE / Biomedical Entity t-SNE



这一页展示实体词如病毒、疾病、症状、蛋白、药物等是否能形成语义聚集。说明不同类别颜色帮助我们检查 domain-specific embeddings 的质量。

Similarity Search

给定目标词，例如 coronavirus，计算余弦相似度并导出 nearest neighbors。

Co-occurrence

从窗口共现中观察术语之间的局部关系，辅助发现疾病、症状、治疗和蛋白的关联。

输出

CSV / XLSX 表格，普通 t-SNE 图，实体分组 t-SNE 图。

生物医学领域词表示项目展示

└─ 结果展示

└─ 相似词与关系挖掘 / Similarity and Relations

这里可以连接到 biomedical knowledge mining：词向量和共现关系可以作为构建知识图谱的初步信号，但还需要实体标准化和关系抽取进一步验证。

Similarity Search

给定目标词，例如 coronavirus，计算余弦相似度并导出 nearest neighbors。

Co-occurrence

从窗口共现中观察术语之间的关联关系，辅助发现疾病、症状、治疗和蛋白的关联。

输出

CSV / XLSX 表格，普通 t-SNE 图，实体分组 t-SNE 图。

从 Notebook 到 Package / Refactoring

模块	文件	职责
Corpus	corpus.py	CSV/JSON/text 语料读取
Tokenization	tokenization.py, bpe.py	多种分词方案
Models	representations.py, ngram.py	统计词表示
Models	word2vec.py, mlm.py	神经词表示
Explore	explore.py	相似词、实体、t-SNE、导出
CLI	cli.py	可复现命令入口

生物学领域词表示项目展示

└─ 工程化重构

└─ 从 Notebook 到 Package / Refactoring

模块	文件	职责
Corpus	corpus.py	CSV / JSON/text 语料读取
Tokenization	tokenization.py, bpe.py	多种分词方案
Models	representations.py, agram.py	统计词表示
Models	word2vec.py, nn.py	神经网络表示
Explore	explore.py	相似词、实体、t-SNE、导出
CLI	cli.py	可复现命令入口

强调重构价值：模块边界清晰、默认路径轻量、重依赖功能可选、测试覆盖核心 smoke path。

- Unit tests cover tokenization, co-occurrence vectors, SimpleBPE, N-gram, and SGNS.
- CLI smoke tests run on existing tokenized samples.
- Heavy dependencies are optional and fail with clear installation messages.
- Original PDFs, notebook, generated figures, and reports are preserved in the repository.

测试命令

```
$env:PYTHONPATH="src"; python -m pytest
```

2026-06-05

生物医学领域词表示项目展示

└─ 工程化重构

└─ 验证与可复现性 / Validation

说明项目现在不仅能展示结果，也更容易被复查、复跑和扩展。

验证与可复现性 / Validation

- Unit tests cover tokenization, co-occurrence vectors, SimpleBPE, N-gram, and SGNS.
- CLI smoke tests run on existing tokenized samples.
- Heavy dependencies are optional and fail with clear installation messages.
- Original PDFs, notebook, generated figures, and reports are preserved in the repository.

测试命令

```
$env:PYTHONPATH="src"; python -m pytest
```

- 项目实现了生物医学文本的端到端词表示 pipeline。
- 多种分词与建模方法提供了从可解释统计模型到上下文模型的完整路线。
- t-SNE、相似词和实体分组分析展示了词向量的语义结构。
- 重构后的代码包提升了复现性、可维护性和后续扩展空间。

生物学领域词表示项目展示

└ 工程化重构

└ 结论 / Conclusion

- 项目实现了生物学文本的端到端词表示 pipeline。
- 多种分词与建模方法提供了从可解释统计模型到上下文模型的完整路线。
- t-SNE、相似词和实体分析展示了词向量的语义结构。
- 重构后的代码包提升了复现性、可维护性和后续扩展空间。

收尾时可以强调：下一步可以做实体标准化、关系抽取和知识图谱构建，把词表示结果转化为更结构化的 biomedical knowledge mining。

Questions?

2026-06-05

生物医学领域词表示项目展示

└─ 工程化重构

└─ Q&A

Q&A

Questions?

结束并邀请提问。